

PROJET 4

Auditez un environnement de données

1. Contexte de l'entreprise

SuperSmartMarket est une chaîne de supermarchés en pleine expansion en France, qui se différencie en intégrant des technologies innovantes pour optimiser et personnaliser l'expérience client.

L'entreprise mise sur :

- **Des coupons promotionnels personnalisés** pour fidéliser les clients.
- **Des recommandations produits basées sur les historiques d'achats.**

Pour soutenir ces ambitions, SuperSmartMarket s'appuie sur un **entrepôt de données OLAP** et des solutions Microsoft (PowerBI, planification de processus) pour analyser et exploiter les flux de données. L'équipe **Data Support**, à laquelle je viens d'être intégrée, a pour mission de garantir la **qualité, la sécurité et la fiabilité des données** pour toute l'entreprise.

2. Problèmes rencontrés

Depuis plusieurs semaines, des incohérences sont détectées dans les données de chiffre d'affaires, qui évoluent de manière inexplicable après coup.

Exemple concret :

- Le 14 août, PowerBI affichait un CA de **275 186,59 €**.
- Quelques jours plus tard, pour la même date, le CA affiché est passé à **284 243,88 €**, alors qu'aucune transaction supplémentaire ne devait être enregistrée (magasins fermés le 15 août).

Les causes potentielles envisagées incluent :

- Des **mise à jour tardives** dans les systèmes de caisse ou de paiement.
- Des **erreurs d'intégration** entre systèmes sources et l'entrepôt OLAP.
- Des **problèmes de synchronisation** dans les processus ETL.

3. Mon rôle dans la résolution du problème

En tant que Data Engineer nouvellement intégrée, ma mission a été d'analyser le flux de données afin d'identifier la source de ces variations de CA.

Prise de connaissance de l'architecture existante

Construction d'un prototype local (POC) :

- Création d'une base de données relationnelle (PostgreSQL).
- Élaboration d'un **schéma relationnel** adapté à partir des données brutes.
- Rédaction d'un **dictionnaire des données** pour documenter la structure.

Vérification des chiffres :

- Calcul du **CA total du 14 août** pour confirmer lequel des deux montants est correct.
- Extraction du **CA par client** pour le top 10 des clients.
- Analyse de la **part du CA encaissé par employé**.

Analyse des causes possibles :

- Comparaison entre données sources et entrepôt OLAP.
- Identification des écarts et des processus susceptibles de les générer.

Proposition de solutions possibles

4. Démarche

1. Compréhension du contexte et cadrage

- Des incohérences dans le chiffre d'affaires apparaissent dans PowerBI, avec des valeurs qui changent dans le temps sans activité réelle (ex. : le CA du 14 août change entre le 15 et le 16 août).
- Aucune documentation n'existe sur la base de données OLAP, ce qui complique la compréhension des traitements effectués sur les données.
- Le reporting repose sur des données instables, remettant en cause la fiabilité des analyses et décisions stratégiques.

2. Collecte et préparation des données

Sources de données :

- Base de données transactionnelle : sales_detail (table de fait), products, employee, clients, calendar
- Logs applicatifs (journaux des actions effectués sur les tables)

Préparation et nettoyage des données


- Préparation du modèle à travers le dictionnaire et le schéma relationnel
- Utilisation d'un client en local pour requêter les tables en mode POC
- Téléchargement des données format XLSX pour l'utilisation de celles ci en local
- Importation des données et choix du typage sur le client Postgresql
- Uniformiser les formats de dates/heures des tables
- Harmoniser les identifiants (produits, commandes, clients).

3. Analyse exploratoire

Comparer le CA jour par jour

Identifier les moments précis où le CA décroche.

Dictionnaire




The screenshot shows a Google Sheet titled "Dictionnaire" with a menu bar (Fichier, Édition, Affichage, Insertion, Format, Données, Outils, Extensions, Aide) and a toolbar. The sheet contains a table with the following data:

	A	B	C	D	E	F	G	H	I
	Champs	Type	Description						
1									
2	ean	Texte / Numérique	Code EAN unique identifiant le produit.						
3	categorie	Texte	Catégorie à laquelle appartient le produit (ex : épicerie, boisson, hygiène).						
4	rayon	Texte	Rayon du magasin où le produit est rangé.						
5	libelle_produit	Texte	Nom ou libellé du produit.						
6	prix	Décimal	Prix unitaire du produit.						
7									
8									
9									
10									
11									
12									
13									
14									
15									
16									
17									
18									
19									
20									
21									
22									
23									
24									
25									
26									
27									
28									
29									
30									
31									
32									
33									

At the bottom of the sheet, there is a tab bar with the following tabs: products (selected), sales_details, clients, employee, and calendar.

<https://docs.google.com/spreadsheets/d/1yNPTujCT3bDNQ4J-TR3XfRKmEG8op08bar3ByZfGCNo/edit?gid=0#gid=0>



pgAdmin 4

File Object Tools Edit View Window Help

Object Explorer

- Domains
- FTS Configurations
- FTS Dictionaries
- FTS Parsers
- FTS Templates
- Foreign Tables
- Functions
- Materialized Views
- Operators
- Procedures
- Sequences
- Tables (6)
 - calendar
 - clients
 - employee
- logs
 - Columns (7)
 - id_user
 - date
 - action
 - table_insert
 - id_ligne
 - champs
 - detail
 - Constraints
 - Indexes
 - RLS Policies
 - Rules
 - Triggers
- products
- sales_detail
 - Columns (6)
 - id_bdd
 - customer_id
 - id_employe
 - ean
 - date_achat
 - id_ticket

Dashboard x SQL x Statistics x Processes x **retails/postgres@PostgreSQL 17 x**

retails/postgres@PostgreSQL 17

Query Query History

Execute script F5

```
1 SELECT
2   sd.*,
3   (DATE '1899-12-30' + sd.date_achat::int) AS date_achat_lisible,
4   (DATE '1899-12-30' + ca.date::int) AS date_calendrier
5 FROM sales_detail sd
6 INNER JOIN products p ON sd.ean = p.ean
7 INNER JOIN clients c ON sd.customer_id = c.customer_id
8 INNER JOIN employee e ON sd.id_employe = e.id_employe
9 INNER JOIN calendar ca ON sd.date_achat::int = ca.date::int
10 ORDER BY date_achat_lisible
```

Data Output Messages Notifications

Showing rows: 1 to 1000 Page No: 1 of 42

	id_bdd [PK] character varying	customer_id character varying	id_employe character varying	ean character varying	date_achat character varying	id_ticket character varying	date_achat_lisible date	date_calendrier date
1	HZD68U15NNY7S1G6DK8NMFDEK7MOVUX3...	CUST-G42Z6WE8QLWJ	b413ca065a762e8cf2e86cfea8b9c1...	6473630445822	45518	t_2693	2024-08-14	2024-08-14
2	1H51BRR800TK9DCIH8M9QCRH3LEAR0JWA...	CUST-CUA37GP8GABQ	a7ada0770091e838e3dcd45265282...	1857802002765	45518	t_4408	2024-08-14	2024-08-14
3	W6VNNWK62XD04QZ5452D5Y0THWQDBTX...	CUST-NHWI0DGNESYI	fa836e3f5fa72d24e07923532169ce	6831886714876	45518	t_3258	2024-08-14	2024-08-14
4	58EC3JD1T2ZAVQZAW4AHFOUEKTR6TZLB...	CUST-IXYXDMN7Q1104	6c1c3292c852c6c593b95cc146b00...	6916826750723	45518	t_1080	2024-08-14	2024-08-14
5	96FE6HA91BRDDF6XRI309B83MSPKIXCIZV	CUST-VR9O54A46EVF	38680e129f45c49322cb12303b7fb...	7930902861368	45518	t_979	2024-08-14	2024-08-14
6	SFJTQXUMU24K7K8LFVB3VOK6A3GQYDC6J...	CUST-VR9O54A46EVF	38680e129f45c49322cb12303b7fb...	110750796338	45518	t_979	2024-08-14	2024-08-14
7	OYCXHDF9300C6IT7A3ZC842J7C50ZNN8K1	CUST-VR9O54A46EVF	38680e129f45c49322cb12303b7fb...	3300979065063	45518	t_979	2024-08-14	2024-08-14
8	GU0P1HRG0YWH6G23JOMMLTOE7DCV8DP...	CUST-0Q6DPH2HT4D4	b5a8777821fdab1a20a4bc0e5f98df...	7189964709179	45518	t_4245	2024-08-14	2024-08-14
9	XOVNXYKADVY2FT9NLCOT05EOVBQM6WIM...	CUST-Y5PASKM343ER	578b43483938010803dcd457753d...	8611110524962	45518	t_3929	2024-08-14	2024-08-14
10	1S416VS4WJ15RHCP51CGTFMAE120ZQP8IV...	CUST-I3MHPVC48DMB	6fa61d0ecae0b563fef18d36b2039c...	8589480061513	45518	t_4180	2024-08-14	2024-08-14
11	7YA8E6QYDEEF97SETMFL6N3SRF1EK93UXXB	CUST-YFH03R4XPYQR	658e6925c1774feb2781a2888c9d4...	9491721740592	45518	t_817	2024-08-14	2024-08-14
12	4UY036R800FSQASOZVSIFL9NQYPC92TKK8	CUST-FB406EI9DXG1	c36c4a024d3b2672042482e25923...	9054957126839	45518	t_4289	2024-08-14	2024-08-14
13	2TD63Z8OQYXRZ5FRRGU80596WHWVZ6YW...	CUST-W8TF0J5PO48E	4efc10ff0f86c772d9949b490eb99ad3	482378487314	45518	t_59	2024-08-14	2024-08-14
14	QGMWXZRWK2M4X50982DAK8HWLJDSARP...	CUST-W8TF0J5PO48E	4efc10ff0f86c772d9949b490eb99ad3	65057604442	45518	t_59	2024-08-14	2024-08-14
15	F8L8T3VYU2MVOTSY8G0DUQ6B16LABMGN...	CUST-S41ZJZAN9S4D	8d1001fbad3d2a60ff7530600ed5d5...	3141385817333	45518	t_3132	2024-08-14	2024-08-14
16	UYBCH5DY549BY04V7AWI8PSMRXWZJ2JZLB...	CUST-AAJP6S67413E	8d1001fbad3d2a60ff7530600ed5d5...	6609808284337	45518	t_501	2024-08-14	2024-08-14
17	BGVUG9CHR0WYGMNNJ6GHCZ2M41YD4KP...	CUST-AAJP6S67413E	8d1001fbad3d2a60ff7530600ed5d5...	8137460505825	45518	t_501	2024-08-14	2024-08-14
18	CJROEPB7IMCGVYE8RDSMV42BJ53V6KW0...	CUST-89UPPH07LEDY	9bc5a4ce59447208da2fb2912c4fbff7	8629575000072	45518	t_4621	2024-08-14	2024-08-14
19	8I18XYTG07RBDH8MYB3024QYD5VZWISL0I	CUST-89UPPH07LEDY	9bc5a4ce59447208da2fb2912c4fbff7	837184296438	45518	t_4621	2024-08-14	2024-08-14
20	KANSIHC6W717EV081J0GM78VE3VW9H0K...	CUST-AAJP6S67413E	8d1001fbad3d2a60ff7530600ed5d5...	4148018290814	45518	t_501	2024-08-14	2024-08-14

Total rows: 41361 Query complete 00:00:00.258

CA du 14 août

```
29
30 SELECT
31     (DATE '1899-12-30' + sd.date_achat::int) AS date_achat_reelle,
32     SUM(p.prix) AS chiffre_affaires_journalier
33 FROM sales_detail sd
34 INNER JOIN products p ON sd.ean = p.ean
35 GROUP BY date_achat_reelle
36 ORDER BY date_achat_reelle;
37
```

	date_achat_reelle date	chiffre_affaires_journalier money
1	2024-08-14	284 143,16 €

CA Top 10 Clients

```
28 select
29     customer_id,
30     sum(p.prix)
31 from sales_detail sd
32 left join products p on sd.ean = p.ean
33 group by customer_id
34 order by sum(p.prix) desc
35 limit 10
36
```

	customer_id character varying	sum money
1	CUST-JNSOZSFORR...	846,86 €
2	CUST-GM6VBAYAB...	666,86 €
3	CUST-L2ST2JHI7K90	644,18 €
4	CUST-WU7ZKQJE4...	608,93 €
5	CUST-9WM83101Q...	582,03 €
6	CUST-ZMAOVX8XY...	576,39 €
7	CUST-3K66CV00H...	571,44 €
8	CUST-CG23SXJDRN...	531,09 €
9	CUST-D8IOFHVUFX...	477,35 €
10	CUST-IHN1HQRI7PYJ	463,73 €

- la part de chiffre d'affaires encaissé par employé.

```

1 SELECT
2   id_employe,
3   (SUM(p.prix) / SUM(SUM(p.prix)) OVER ()) * 100 AS part_par_employe,
4   sum(p.prix)
5 FROM sales_detail sd
6 LEFT JOIN products p ON sd.ean = p.ean
7 GROUP BY id_employe
8 ORDER BY part_par_employe DESC;

```

Data Output Messages Notifications

	id_employe character varying	part_par_employe double precision	sum money
1	f491076a1ff2d873ebea809c11144542	2.751718535121521	7 818,82 €
2	e01e752175e05f00c8314ccb8da4c...	2.722627565625722	7 736,16 €
3	8d1001fbad3d2a60ff7530600ed5d5...	2.4618364911546697	6 995,14 €
4	6c1c3292c852c6c593b95cc146b00c...	2.3285656427555743	6 616,46 €
5	a7ada0770091e838e3dcd45265282...	2.2813253713374624	6 482,23 €
6	2477db17c02f512ebc4b20f01a7edb...	2.238737684201161	6 361,22 €
7	528c733809cb51a3634befb260b5d2...	2.154100770893095	6 120,73 €
8	1c1d83678cc463b52366dae07cd14...	2.1511585920280467	6 112,37 €
9	dd595f0f0b3400df2908f0be7723dad4	2.1507397890556295	6 111,18 €
10	c4f0909120cfde7086a3c1a56e96a0...	2.144260660717647	6 092,77 €
11	4853b03deab973a1a8e466025bce5...	2.1080359632799186	5 989,84 €
12	3084187cfabdb2a7de260f4387241c...	2.0821792789240465	5 916,37 €
13	f6cd8ba3485769b3ad9bab5b772585...	2.07922654200087	5 907,98 €

5. Explication de l'écart

- Le **14 août** -> CA affiché = **275 186,59 €**
- Le **15 août** -> jour férié, magasins fermés, donc pas de ventes nouvelles

Mais le **16 août** → le CA du **14 août** apparaît comme **284 243,88 €**

Nous retrouvons exactement ce montant en calculant les insert du 15 août
soit un écart de 9057€

Pourquoi ?

Les faits

- Certaines transactions sont enregistrées en décalé
- Les inserts dans `sales_detail` continuent à arriver après le jour J.

6. Audit

- Comment le problème a été détecté ?

Le problème a été repéré par l'équipe Business Intelligence lors d'un contrôle régulier des indicateurs financiers sur PowerBI.

En comparant les données affichées à différents moments, ils ont constaté que le chiffre d'affaires d'une même date pouvait varier d'un jour à l'autre, alors que les transactions pour cette période étaient supposées figées.

- Analyse et résolution

<https://docs.google.com/document/d/1cXSuNWeI4Cb71vgQeHfTyzj-qvvBpYwJ/edit>

7. Recommandation de solutions

ajouter un insert time stamp dans la table sales_details pour agréger par insert timestamps directement dans la table sales_details

Triggers + Logs d'Audit

- Mise en place de **triggers** sur la table sales (et sales_detail) pour capturer **toute modification a posteriori**.
- À chaque **INSERT / UPDATE / DELETE**, un enregistrement est écrit dans une table audit_logs avec :
 - **ancienne valeur** (par ex. prix, quantité, date de vente avant modif)
 - **nouvelle valeur**
 - **utilisateur ou process** ayant fait la modification
 - **horodatage** précis de la modification (changed_at).
- Cela permet d'identifier si le CA du 14/08 a évolué parce qu'une ligne a été insérée en retard, corrigée ou supprimée

Procédures Stockées

- Les calculs de CA (journalier, hebdo, par client, etc.) sont **centralisés dans des procédures stockées** au lieu de requêtes ad hoc.
- Ces procédures :
 - appliquent toujours les mêmes règles (quantité × prix de vente capturé, et non prix courant du produit),
 - prennent en compte la date de vente réelle et non la date d'insertion,
 - garantissent une **cohérence des chiffres**

Contraintes d'unicité / cohérence

- **PRIMARY KEY (id_bdd)** → chaque ligne de vente est unique.
- **UNIQUE (ean, date_vente, id_ticket)** (si pertinent) → évite d'avoir la même vente insérée deux fois.