

Proposition de texte pour ton rendu

1. Justification des composants cloud sélectionnés

Dans le cadre de la modernisation de l'infrastructure d'InduTechData, l'architecture hybride proposée repose sur plusieurs services AWS complémentaires, en cohérence avec les besoins exprimés : stockage de données non structurées, entrepôt analytique, streaming temps réel, extension de l'Active Directory et sécurisation des échanges entre le SI on-premise et le cloud. Le contexte métier impose en effet de gérer un cluster SQL Server de 40 To, un SAN de 10 To pour les logs et fichiers de capteurs, un Active Directory on-premise, ainsi que des flux IoT en forte croissance.

Le premier composant retenu est **Amazon S3** pour le stockage des données non structurées. Ce choix répond directement au besoin de stocker les logs, les fichiers utilisateurs, les exports du SAN et les données IoT brutes. S3 est adapté à ce rôle car il offre un stockage objet hautement scalable, avec une facturation à l'usage, sans minimum contractuel. AWS précise que le coût dépend principalement du volume stocké, du type de stockage choisi, des requêtes et des transferts, ce qui en fait une brique souple pour un usage de type data lake ou staging.

Le deuxième composant est **Amazon Redshift** comme entrepôt de données analytique. Ce service permet de centraliser les données structurées et semi-structurées, puis d'exécuter des requêtes SQL complexes pour le reporting et l'analyse. Il répond au besoin formulé dans l'exercice de disposer d'un data warehouse cloud capable de supporter des usages analytiques. Redshift est aussi cohérent avec l'idée de séparer l'ingestion, le stockage intermédiaire et l'analyse, en chargeant les données depuis S3 vers l'entrepôt. AWS indique que Redshift existe en mode provisioned ou serverless, avec une montée en charge jusqu'au pétaoctet et une tarification de départ à l'heure.

Pour la synchronisation des données issues du cluster **SQL Server on-premise**, le service retenu est **AWS Database Migration Service (AWS DMS)**. Son rôle est d'assurer la réplication initiale puis incrémentale grâce au CDC, afin de transférer les modifications sans recharger entièrement les tables à chaque cycle. Ce choix répond explicitement à la consigne demandant d'expliquer comment synchroniser SQL Server avec la solution cloud choisie. La chaîne recommandée est : **SQL Server** → **AWS DMS** → **S3 (staging)** → **Redshift**. Le passage par S3 est important car il découple la réplication de la consommation analytique, permet l'historisation et facilite le reprocessing en cas d'erreur de chargement. AWS présente DMS comme une solution de migration/réplication avec facturation horaire ou serverless, adaptée aux migrations continues avec CDC.

Pour les flux temps réel, le composant demandé par l'énoncé est **Redpanda**. Il constitue la plateforme de streaming principale pour les données IoT et les logs, compatible avec l'écosystème Kafka. Dans l'architecture proposée, les sources IoT envoient leurs événements vers Redpanda, qui orchestre et distribue les flux avant leur persistance dans S3 puis, selon les besoins, leur intégration dans Redshift. Ce choix est cohérent avec

l'objectif de traiter des flux continus rapidement et de manière fiable. L'intérêt de Redpanda ici est d'offrir une couche de streaming dédiée, sans dépendre d'un batch classique pour les événements capteurs.

Redpanda peut être utilisé sur AWS comme plateforme de streaming compatible Kafka. Il peut être déployé en service managé via Redpanda Cloud ou sur EC2 pour un POC. Les producteurs envoient les événements dans des topics Redpanda, puis les consommateurs ou connecteurs les exploitent pour alimenter S3, Redshift ou des traitements Spark. Les échanges sont sécurisés via TLS, avec un accès réseau privé via VPC, PrivateLink, VPC Peering, VPN ou Direct Connect selon le niveau de sécurité attendu.

Pour la gestion des identités et des accès, le composant retenu est **AWS Directory Service**. Il permet d'étendre l'Active Directory on-premise vers AWS et d'assurer une gestion unifiée des identités, des groupes et des permissions. Dans le schéma, le flux principal correspondant est : **Active Directory on-premise** → **AWS Directory Service**, avec comme finalité la synchronisation des identités et le SSO. Ce choix répond directement à la consigne de proposer un service pour étendre l'AD au cloud. AWS précise que le service est facturé à l'heure par contrôleur de domaine géré.

Enfin, la liaison entre le datacenter et AWS repose sur une **connexion sécurisée de type Site-to-Site VPN**, avec possibilité d'évolution vers **Direct Connect** si les volumes ou les exigences de stabilité augmentent. Le VPN permet de relier le réseau on-premise au VPC AWS de manière chiffrée. AWS indique qu'un Site-to-Site VPN est facturé à l'heure lorsqu'il est actif, hors trafic sortant éventuel, ce qui en fait un point d'entrée acceptable pour une première architecture hybride.

Pour les données fichiers du **SAN**, le flux le plus cohérent est **SAN** → **AWS DataSync** → **S3**, car le SAN transporte principalement des fichiers non structurés et non des tables répliquées. AWS DataSync est justement conçu pour transférer et synchroniser des données entre un stockage on-premise et AWS, avec une facturation au volume transféré.

Réseaux :

Le VPN site-to-site permet de relier de manière sécurisée le réseau on-premise de l'entreprise à son environnement AWS. Il établit un tunnel chiffré entre l'infrastructure locale et le VPC AWS afin que les ressources internes puissent communiquer avec les services cloud comme si elles faisaient partie du même réseau étendu.

Côté entreprise, la connexion part du réseau on-premise, où se trouvent les systèmes existants comme le cluster SQL Server, l'Active Directory ou les applications internes. Ce réseau est connecté à un Customer Gateway, c'est-à-dire l'équipement réseau de l'entreprise (généralement un routeur ou un firewall compatible VPN) chargé d'initier la connexion sécurisée vers AWS.

Les données transitent ensuite par Internet via un tunnel VPN IPsec. Elles passent bien par le réseau public, mais elles sont entièrement chiffrées pendant le transport. Cela garantit la confidentialité et l'intégrité des échanges entre l'infrastructure on-premise et AWS, même en utilisant Internet comme support de transport.

Côté AWS, la connexion arrive sur une Virtual Private Gateway. Cette passerelle VPN est le point d'entrée sécurisé du VPC côté AWS. Elle reçoit le trafic en provenance du tunnel VPN, le déchiffre, puis le route vers les ressources autorisées à l'intérieur du VPC.

Une fois dans le VPC AWS, les flux circulent dans un réseau privé isolé, où se trouvent les services cloud de l'entreprise comme AWS DMS, EC2, Redshift ou d'autres composants de traitement et de stockage. Le VPC joue ici le rôle d'extension sécurisée du réseau de l'entreprise dans le cloud.

Cette architecture permet donc d'étendre le système d'information on-premise vers AWS de manière sécurisée, tout en assurant une communication privée entre les environnements. Elle est particulièrement adaptée dans une architecture hybride, où une partie des systèmes reste hébergée localement tandis qu'une autre est déployée dans le cloud.

1. Sécurité des données au repos (Data at Rest)

Amazon S3

- **SSE-S3** : chiffrement natif géré par S3
- **SSE-KMS** : chiffrement avec clés gérées par AWS KMS
- **SSE-C** : chiffrement avec clés fournies par le client

Le plus courant en entreprise : **SSE-KMS**.

Amazon Redshift

- chiffrement natif des données et snapshots
- intégration avec **AWS KMS** pour la gestion des clés

Amazon EBS

(si volumes attachés à EC2 / SQL / outils intermédiaires)

- chiffrement des volumes EBS
- snapshots chiffrés
- gestion via **AWS KMS**

AWS Backup

- sauvegardes centralisées chiffrées
- protection des snapshots et rétention sécurisée

AWS KMS (Key Management Service)

C'est le service central de gestion des clés de chiffrement côté AWS.

Il permet de :

- créer et gérer les clés,
- contrôler leur rotation,
- gérer les accès,
- auditer leur usage.

C'est le composant central pour protéger les données au repos.

Sécurité on rest et on transit :

Côté AWS, la sécurité repose sur plusieurs services complémentaires :

AWS KMS pour la gestion des clés de chiffrement, **S3 / Redshift / EBS** pour le chiffrement des données au repos, **Site-to-Site VPN / TLS / Direct Connect** pour sécuriser les échanges en transit, **IAM / Secrets Manager / Directory Service** pour le contrôle d'accès, et **CloudTrail / CloudWatch / GuardDuty** pour l'audit et la surveillance de sécurité.

AWS Site-to-Site VPN

- tunnel chiffré **IPsec** entre on-prem et AWS
- protège les échanges entre les deux environnements

AWS Direct Connect

- liaison privée dédiée entre on-prem et AWS
(plus stable que VPN, souvent combinée avec chiffrement applicatif TLS)

TLS / SSL

Utilisé pour :

- SQL Server → DMS
- DMS → S3
- applications → Redshift
- services → APIs

Amazon API Gateway

(si APIs exposées)

- HTTPS natif
- TLS termination
- sécurisation des appels API

Elastic Load Balancer (ELB / ALB / NLB)

- terminaison TLS
- chiffrement des flux entrants vers les applications

Amazon MSK / Redpanda (Kafka compatible)

- TLS pour sécuriser les flux de streaming
- chiffrement des producteurs / consommateurs

2. Évaluation de compatibilité avec le SI on-premise

L'architecture proposée est globalement **compatible** avec le système existant d'InduTechData, car elle respecte les composants déjà en place tout en ajoutant des capacités cloud ciblées. Elle ne remplace pas brutalement le SI on-premise : elle s'y connecte. Cette approche est pertinente puisque l'entreprise souhaite conserver SQL

Server, l'ERP/CRM et Active Directory, tout en modernisant le stockage, l'analytique et le traitement temps réel.

Sur le plan de la **sécurité et de la conformité**, plusieurs points sont favorables. D'abord, les échanges entre on-premise et AWS peuvent être protégés via VPN. Ensuite, AWS Security Hub recommande explicitement que les instances DMS ne soient pas publiques lorsque la source et la cible sont dans des réseaux connectés par VPN, Direct Connect ou peering, et que les endpoints DMS utilisent SSL/TLS. Cela conforte le choix d'un déploiement DMS privé dans le VPC. Enfin, AWS Directory Service permet d'unifier la gestion des identités entre l'environnement historique et le cloud, ce qui évite de créer des comptes séparés et réduit les risques liés aux droits dispersés.

Du point de vue de l'**interopérabilité (capacité de plusieurs systèmes différents à communiquer, échanger des données et fonctionner ensemble correctement,)**, l'architecture est cohérente car chaque flux utilise l'outil adapté à sa nature. Les données relationnelles de SQL Server sont répliquées via DMS avec CDC. Les fichiers et données non structurées du SAN sont copiés via DataSync vers S3. Les flux IoT sont traités en streaming par Redpanda. Cette séparation évite de vouloir faire porter à un seul outil des usages trop différents. De plus, la présence de S3 comme zone de staging rend possible l'automatisation des traitements et facilite les reprises sur incident. Cela répond bien à l'exigence de l'exercice d'automatiser les flux et d'assurer une interopérabilité fluide avec l'existant.

En matière de **scalabilité**, l'architecture répond correctement à la croissance des données IoT et des logs. L'entreprise enregistre déjà une hausse mensuelle de 50 Go de données temps réel ; le fait d'utiliser S3 pour absorber les volumes bruts, Redpanda pour le streaming et Redshift pour l'analytique permet de mieux répartir les charges. S3 et Redshift ont une logique de montée en charge souple, tandis que DMS permet une réplication incrémentale sans recharger l'intégralité des 40 To à chaque fois.

Les **avantages** principaux sont donc la modernisation progressive du SI, la séparation claire entre batch et temps réel, l'amélioration de la résilience grâce au staging S3, et la continuité de la gestion des identités. Les **limitations** concernent surtout la complexité d'exploitation : il faut surveiller plusieurs briques, maîtriser les coûts de transfert et de stockage, et définir précisément les règles de chargement vers Redshift. Il faut aussi choisir un mode d'hébergement réaliste pour Redpanda, ce qui n'est pas détaillé dans l'énoncé et devra être cadré au niveau projet. Les **points d'attention** majeurs sont le chiffrement systématique, le placement des ressources dans des subnets privés, le monitoring des tâches DMS, la gouvernance des accès, et le suivi budgétaire.

3. Première estimation de coûts

- **Amazon S3** : coût variable selon stockage, requêtes et transferts ; modèle purement à l'usage.
- **Amazon Redshift** : à partir d'environ **0,543 USD/heure** en provisioned ou **1,50 USD/heure** en serverless, hors stockage/consommations additionnelles.
- **AWS DMS** : coût horaire des instances de réplication ou consommation serverless ; prévoir aussi le stockage de logs et les éventuels transferts réseau.

- **AWS Directory Service** : environ **0,65 USD/heure** pour un directory hybride avec deux contrôleurs par défaut dans l'exemple AWS cité.
- **AWS Site-to-Site VPN** : exemple AWS à **0,05 USD/heure** pour une connexion active, hors coûts de trafic sortant et éventuel Transit Gateway.
- **AWS DataSync** : tarification au volume transféré, donc directement liée aux flux SAN → S3.
- **Redpanda**, Le coût dépendra du mode d'hébergement retenu (self-managed sur EC2, conteneurisé, ou autre), du nombre de nœuds, du stockage et du niveau de disponibilité attendu

Monitoring des coûts

Pour maîtriser les coûts AWS, on peut utiliser :

AWS Budgets :

Permet de définir un budget mensuel et de recevoir des alertes quand les coûts dépassent un seuil prévu.

CloudWatch Billing Alarms :

Permet de créer une alarme quand les coûts estimés dépassent un montant défini.

CloudWatch pour Redshift :

Permet de surveiller l'usage de Redshift : charge, requêtes, performances, consommation, erreurs, etc.