

> PIPELINE_DEPLOYMENT_SUCCESS

PROJET 10

ORCHESTRATION DES FLUX

Industrialisation du traitement de données pour BottleNeck : Automatisation du nettoyage, de la fusion ERP/Web et détection statistique des vins premium.

KESTRA

PYTHON

DUCKDB

DOCKER

| Contexte & Problématique

Silos de Données

-  **Système ERP** : Données produits et stocks.
-  **E-Commerce** : CMS Ventes en ligne.
-  **Traitement Manuel** : Risques d'erreurs et perte de productivité.



Architecture Globale



KESTRA

Orchestrateur open-source
"Everything-as-Code". Planification,
gestion des triggers et surveillance du
workflow.



SCRIPTS PYTHON

Logique métier encapsulée dans des
containers Docker : Nettoyage,
dédoublonnage et analyse Z-Score.




DUCKDB

Moteur SQL In-Process ultra-rapide
pour la fusion des 3 sources et le calcul
massif du chiffre d'affaires.


Architecture Globale

Orchestrateur : Kestra
scripts python pour : le
nettoyage,
dédoublonnage, fusion,
calcul, z-score



Architecture Globale

Orchestrateur : Kestra
scripts python pour : le nettoyage, dédoublonnage, fusion, calcul, z-score



| Nettoyage & Qualité

- ✔ **Dédoublonnage** : sur product_id pour l'ERP et sur SKU pour le web
- ▼ **Traitement Valeurs Nulles** : Suppression des lignes comportant des valeurs manquantes sur les clés de jointure et les champs métier essentiels (product_id, id_web, sku, price, total_sales)




Détection des Vins Premium

Méthode du Z-Score

Détection statistique des outliers de prix. Un vin est considéré premium si son prix s'écarte significativement de la moyenne catalogue.

$$z = \frac{x - \mu}{\sigma}$$

> Condition : $z > 2.0$



| Résultats Obtenus

714

PRODUITS ANALYSÉS

30

VINS PREMIUM DÉTECTÉS

100%

PIPELINE AUTOMATISÉ

Exports générés : vins_premium.csv, vins_ordinaires.csv, rapport_ca.xlsx, donnees_fusionnees.csv

Tests réalisés

Tests réalisés

Afin de garantir la qualité des données produites par le pipeline, plusieurs tests automatisés ont été intégrés au workflow Kestra :

- **Test d'absence de doublons** : vérification qu'aucun identifiant produit (`product_id`) ou référence (`sku`) n'est présent plusieurs fois dans le fichier fusionné.
- **Test de valeurs manquantes** : contrôle de la présence des informations essentielles (identifiant produit, référence, prix, ventes et chiffre d'affaires) afin de détecter d'éventuelles données incomplètes.
- **Test de cohérence du chiffre d'affaires** : comparaison du chiffre d'affaires total calculé à partir des données fusionnées avec le montant exporté dans le rapport Excel pour s'assurer de l'exactitude des calculs.
- **Test de cohérence de la classification des vins** : vérification que chaque vin est correctement classé comme « premium » ou « ordinaire » selon son z-score et que le total des vins classifiés correspond au nombre total de vins analysés.
- **Test de fusion**

Industrialisation & Planning

Cron Schedule : "0 9 15 * *"

Le pipeline s'exécute automatiquement tous les 15 du mois à 09h00 pour traiter les nouvelles ventes et mettre à jour les inventaires marketing.

Résultats obtenus

Ce projet a permis de mettre en place un pipeline de traitement de données automatisé permettant d'industrialiser l'analyse réalisée initialement de manière manuelle.

Grâce à l'utilisation de Kestra, Python et DuckDB, l'ensemble du workflow peut désormais :

- vérifier la présence des fichiers sources ;
- nettoyer et fusionner les données ERP et WEB ;
- calculer automatiquement le chiffre d'affaires ;
- identifier les vins premium à l'aide d'une méthode statistique ;
- générer des exports exploitables par les équipes métier.

Des contrôles qualité ont également été intégrés afin de garantir la fiabilité des résultats et d'arrêter automatiquement le workflow en cas d'erreur ou d'incohérence des données.

Le workflow est entièrement planifié et exécutable automatiquement chaque mois, ce qui permet de réduire les traitements manuels, sécuriser les analyses et améliorer la disponibilité des indicateurs métier.



QUESTIONS ?